Projet SDP – Jalon 2

Apprentissage de deux modèles MR-Sort sur une clientèle segmentée (inv-2-MR-Sort)

Mohamed Salh Mohamed Chebli Quentin Robidou

Octobre 2026

1 Problème

Chaque objet $x = (x_1, \ldots, x_n)$ du learning set est affecté à l'une de p catégories ordonnées. On fait l'hypothèse que ces affectations proviennent de *deux* segments de clientèle, chacun décrit par son propre modèle MR-Sort (profils $b^1, \ldots, b^{p-1}$, poids w, seuil λ), mais on ne sait pas à quel segment appartient chaque objet. Il faut donc, simultanément, partitionner le learning set en deux et apprendre un modèle MR-Sort par partie. Apprendre un seul MR-Sort étant déjà NP-difficile, nous proposons une heuristique qui s'appuie sur la bibliothèque `lincs` pour apprendre chaque modèle.

2 Méthode d'apprentissage

2.1 Principe : alternance partition / apprentissage

L'heuristique suit le même schéma que les k-moyennes, en remplaçant le centre de chaque groupe par un modèle MR-Sort :

1. partir d'une partition initiale des objets en deux segments ;
2. apprendre un modèle MR-Sort sur chaque segment avec `lincs` ;
3. évaluer chaque objet avec les deux modèles et déplacer vers l'autre segment les objets que l'autre modèle explique mieux ;
4. recommencer jusqu'à épuisement du budget de temps, en conservant la meilleure partition rencontrée.

La qualité d'une partition est la proportion d'objets correctement classés par le modèle de leur segment (critère principal), puis la marge totale (critère secondaire, voir ci-dessous). On conserve la meilleure partition rencontrée et non la dernière, car l'apprentissage par `lincs` étant heuristique, une itération peut être moins bonne que la précédente.

2.2 Apprentissage d'un modèle MR-Sort avec lincs

Chaque modèle est appris avec l'heuristique de Sobrie (`LearnMrsortByWeightsProfilesBreed`). Elle fait évoluer une population de 9 modèles et alterne deux sous-problèmes :

— **poids et seuil à profils fixés** : c'est un programme linéaire (le problème de la question iv du jalon 1), résolu de façon exacte par le solveur GLOP ;

— **profils à poids fixés** : une heuristique locale déplace les seuils critère par critère pour augmenter le nombre d'objets bien classés.

Deux choix encadrent cet apprentissage :

— **croisement (*breeding*)** : à chaque itération, les 4 modèles les moins performants de la population sont réinitialisés (nouveaux profils tirés au hasard, puis nouveaux poids). Cela évite que toute la population reste bloquée dans le même minimum local ;

— **arrêt** : l'apprentissage s'arrête dès que tous les objets sont bien classés, après 10 itérations sans progrès, ou après **4 secondes**. Cette limite est indispensable car un modèle est réappris à chaque itération de l'heuristique, pour chacun des deux segments : il faut que chaque apprentissage reste court.

Les poids renvoyés par `lincs` sont définis avec un seuil de majorité égal à 1. Nous les normalisons (somme égale à 1, et $\lambda = 1/\sum_i w_i$) pour que les marges des deux modèles soient comparables.

2.3 Métrique de réaffectation

Pour un objet x de catégorie réelle k et un modèle donné, on calcule :

1. l'**écart de catégorie** $|\hat{k}(x) - k|$, où $\hat{k}(x)$ est la catégorie prédite par le modèle ;
2. la **marge de concordance**, analogue objet par objet de la marge maximisée au jalon 1 :

$$\text{marge}(x) = \min\Big(\sum_{i:\, x_i \geq b_i^{k-1}} w_i - \lambda \ , \quad \lambda - \sum_{i:\, x_i \geq b_i^{k}} w_i \Big),$$

(un seul terme pour les catégories extrêmes). Elle est positive si x est bien classé, et d'autant plus grande qu'il l'est avec une avance confortable sur le seuil.

Un objet est candidat au changement de segment si l'autre modèle commet un écart de catégorie plus faible, ou le même écart avec une meilleure marge. L'écart seul produit énormément d'égalités (beaucoup d'objets sont bien classés par les deux modèles) ; la marge, continue, permet de les départager.

2.4 Choix techniques de la réaffectation

— **Au plus 10 % des objets déplacés par itération**, en priorité ceux dont l'erreur baisse le plus, puis ceux dont la marge augmente le plus. Déplacer tous les candidats d'un coup fait osciller la partition (les deux modèles peuvent s'échanger leurs segments), et laisse peu de chance aux modèles de s'adapter progressivement.

— **Taille minimale de 15 % par segment**. Un modèle MR-Sort compte $(p-1)n + n + 1$ paramètres (jusqu'à 51 pour $n = 10$, $p = 5$). Un segment presque vide n'aurait pas assez d'objets pour les déterminer : le modèle serait mal contraint (sous-apprentissage) et pourrait, à l'inverse, expliquer parfaitement les quelques objets qu'il contient, ce qui bloquerait la partition. Un segment trop petit au départ est complété par des objets tirés au hasard.

2.5 Deux partitions de départ

L'heuristique ne converge que vers un optimum local, qui dépend du point de départ. Nous comparons deux initialisations :

— **départ aléatoire** : chaque objet est affecté à un segment à pile ou face ;

— **départ modèle unique** (*single model*) : on apprend d'abord un seul MR-Sort sur tout le learning set. Ce modèle ne peut pas expliquer les deux comportements à la fois, mais il a de bonnes chances d'être proche de l'un des deux modèles, en particulier de celui du segment majoritaire. Les objets qu'il classe bien forment le premier segment, ceux qu'il classe mal le second : la partition de départ est alors déjà proche de la vraie.

2.6 Budget de temps déterministe

Plutôt qu'un nombre fixe d'itérations, chaque méthode dispose du même budget de **90 secondes**, qui inclut, pour le départ modèle unique, l'apprentissage du modèle initial. La boucle continue jusqu'à la fin du budget, même si plus aucun objet ne change de segment (les modèles sont alors réappris avec de nouvelles graines). À chaque itération, nous enregistrons le temps écoulé

et la meilleure précision atteinte. Ce choix permet de tracer le taux d'erreur en fonction du temps et de comparer à la fois la qualité finale et la *vitesse de convergence* des deux méthodes, à coût de calcul identique.

3 Protocole expérimental

Nous avons appliqué les deux méthodes aux 72 datasets fournis, qui croisent : deux types (A et B) ; trois tailles de problème ($n = 6, p = 3$; $n = 8, p = 4$; $n = 10, p = 5$) ; trois tailles de learning set (300, 600 et 1 200 objets) ; deux répartitions des segments (50/50 et 75/25) ; et deux niveaux de bruit (0 % et 10 % d'affectations erronées). Le **taux d'erreur** est la proportion d'objets mal classés par le modèle de leur segment. Les courbes tracent, à chaque instant, le taux d'erreur de la meilleure partition atteinte, moyenné sur un groupe de datasets ; la zone colorée est l'intervalle interquartile entre datasets. Une courbe ne commence qu'au moment où tous les datasets du groupe ont terminé leur première itération (environ 9 s pour le départ aléatoire et 13 s pour le départ modèle unique, qui apprend d'abord son modèle initial).

4 Résultats

4.1 Le départ modèle unique converge plus vite et plus bas

	1 modèle seul	Départ aléatoire	Départ modèle unique
Taux d'erreur final (72 datasets)	32,2 %	9,2 %	**7,0 %**
Datasets où la méthode est meilleure	–	14	**55**
Temps médian pour atteindre l'erreur finale (à 0,5 point près)	–	69 s	**48 s**

TABLE 1 – Résultats après 90 s par méthode (3 datasets à égalité).

Un seul modèle MR-Sort laisse près d'un tiers des objets mal classés, ce qui confirme la présence de deux comportements. Les deux heuristiques réduisent fortement cette erreur, mais le départ modèle unique est meilleur sur 55 datasets sur 72 (tableau 1). La figure 1 montre pourquoi : il **part d'un point bien meilleur** (environ 12 % d'erreur contre 23 % pour le départ aléatoire), ce qui lui permet de **converger plus vite** (48 s contre 69 s en médiane) et de **finir plus bas**. À 90 s, la courbe du départ aléatoire descend encore : avec plus de temps l'écart se réduirait probablement, mais à budget égal le départ modèle unique est nettement plus efficace.

4.2 Les datasets de type B sont plus difficiles

Comme attendu, les datasets de type B sont plus difficiles que ceux de type A (figure 2) : les deux méthodes y partent de plus haut et finissent avec 2,5 à 3,5 points d'erreur de plus. Le classement des méthodes est le même dans les deux cas, et l'avantage du départ modèle unique est même plus marqué sur le type B.

4.3 Une erreur irréductible due au bruit

La moitié des datasets comporte 10 % d'affectations bruitées, qu'aucun couple de modèles ne devrait pouvoir expliquer. Sur l'ensemble des 72 datasets, on s'attend donc à une erreur *irréductible* d'environ $0{,}5 \times 0\,\% + 0{,}5 \times 10\,\% = 5\,\%$: avec un taux d'erreur total de 7,0 %, l'erreur imputable à notre méthode n'est que de l'ordre de 2 points. La figure 3 sépare les deux cas : sans bruit, le départ modèle unique atteint 3,0 % d'erreur (contre 5,4 % pour le départ aléatoire) ; avec 10 % de bruit, il finit à 11,1 %, soit environ 1 point au-dessus du plancher.

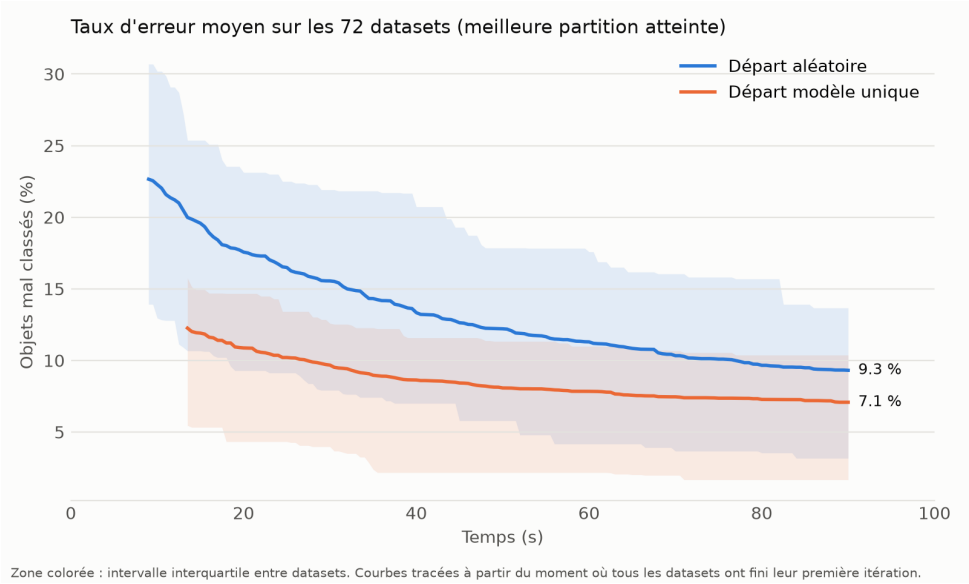
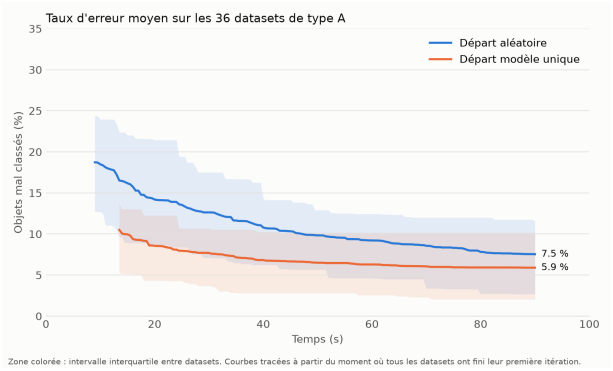
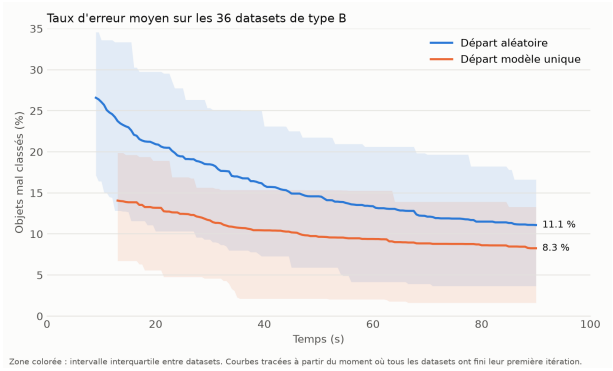


FIGURE 1 – Taux d'erreur moyen en fonction du temps sur les 72 datasets.



(a) Type A : 7,5 % (aléatoire) contre 5,9 %.



(b) Type B : 11,1 % (aléatoire) contre 8,3 %.

FIGURE 2 – Taux d'erreur moyen selon le type de dataset (même échelle).

L'écart entre datasets bruités et non bruités (8,1 points) est cependant inférieur aux 10 points attendus, et certaines exécutions descendent sous la ligne des 10 % (jusqu'à 3,7 % sur un dataset). Cela s'explique en partie par le hasard, mais aussi probablement par un léger **surapprentissage du bruit**, de l'ordre de 1 à 2 % : avec deux modèles, un objet dont la catégorie a été modifiée par le bruit peut être correctement expliqué par l'*autre* modèle, et l'heuristique le place alors dans l'autre segment.

4.4 Un avantage encore plus net sur les segments déséquilibrés

Comme attendu, le départ modèle unique est encore plus efficace quand les segments sont déséquilibrés (figure 4). En 75/25, le modèle unique apprend surtout le segment majoritaire, et ses erreurs désignent bien le segment minoritaire : la partition de départ ne contient en moyenne qu'environ 10 % d'erreur (6,4 % seulement sur les datasets sans bruit), contre 20 % pour le départ aléatoire. Il converge alors en 30 à 40 s et finit à 6,1 % d'erreur, contre 8,9 % (2,3 % contre 5,2 % sans bruit). En 50/50, le modèle unique est un compromis entre les deux comportements et son avantage se réduit (8,0 % contre 9,7 %).

Enfin, la difficulté augmente avec la taille du learning set et du problème : sur les datasets de 1 200 objets, le départ aléatoire n'a pas convergé en 90 s (13,0 % d'erreur contre 9,2 % pour le départ modèle unique, figure 5), car chaque apprentissage y est plus long et le budget permet moins

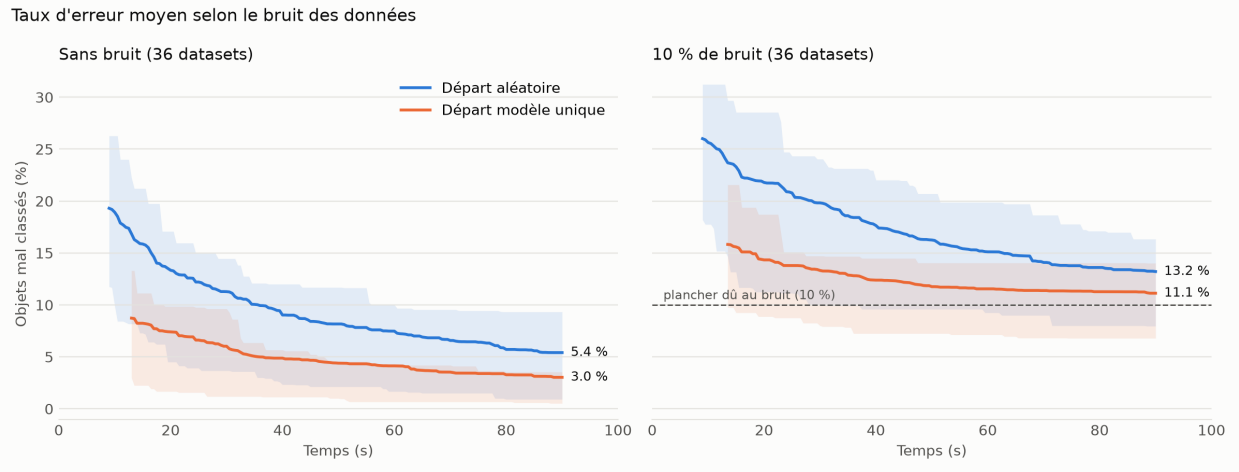


FIGURE 3 – Taux d'erreur moyen sans bruit et avec 10 % de bruit (ligne pointillée : plancher dû au bruit).

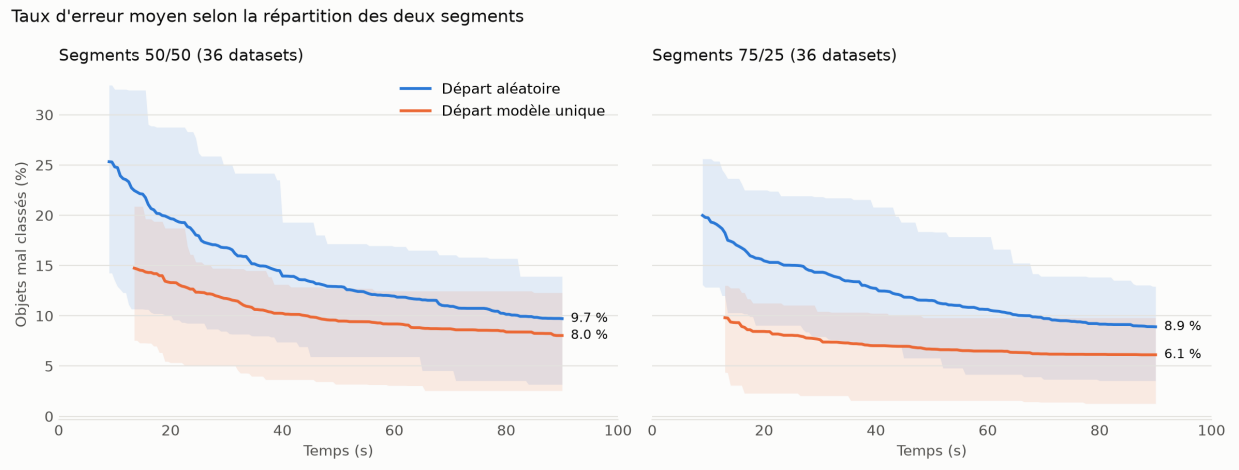


FIGURE 4 – Taux d'erreur moyen selon la répartition des segments.

d'itérations.

5 Validation empirique sur données synthétiques

Sur les datasets fournis, le segment de chaque objet est inconnu : un faible taux d'erreur montre que deux modèles *expliquent* bien les données, mais pas qu'ils sont les *vrais* modèles. Pour le vérifier, nous générons deux modèles MR-Sort M'_1 et M'_2 (tirés comme dans Leroy, Mousseau et Pirlot, 2011), des objets uniformes dans $[0,1]^n$ répartis aléatoirement entre les deux segments, et classons chaque objet avec le modèle de son segment. Nous lançons ensuite les deux heuristiques (90 s chacune) sur ce learning set.

Comme vu au jalon 1 (question iii), deux modèles MR-Sort aux paramètres différents peuvent prendre exactement les mêmes décisions : comparer les poids, seuils ou profils appris à ceux de M'_1 et M'_2 n'aurait pas de sens. La validation est donc **empirique**, fondée uniquement sur les décisions :

— **accord des modèles** : sur un ensemble de test de 10 000 objets nouveaux, proportion d'objets affectés à la même catégorie par M'_j et par le modèle appris M^*_j ;

— **partition retrouvée** : proportion d'objets du learning set remis dans leur vrai segment, en prenant la meilleure des deux numérotations (les étiquettes des segments sont interchangeables). Nous la mesurons sur les seuls *objets discriminants*, que M'_1 et M'_2 classent différem-

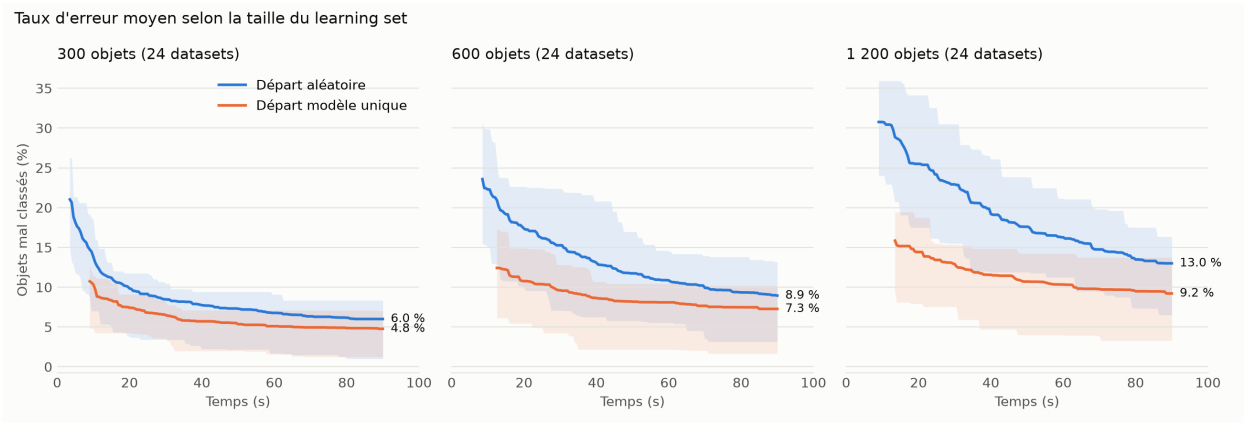


FIGURE 5 – Taux d'erreur moyen selon la taille du learning set.

ment : un objet que les deux vrais modèles classent dans la même catégorie peut être placé dans l'un ou l'autre segment sans erreur, et ne permet pas de juger.

Configuration	Seg.	Départ	Erreur (appr.)	Bon segment (discr.)	Accord M'_1/M^*_1	Accord M'_2/M^*_2
$n = 6$, $p = 3$, 300 obj.	50/50	aléatoire	1,0 %	79,4 %	68,2 %	76,8 %
		modèle unique	0,8 %	**81,5 %**	**76,9 %**	**82,0 %**
$n = 6$, $p = 3$, 600 obj.	50/50	aléatoire	0,3 %	**82,3 %**	**73,2 %**	**79,6 %**
		modèle unique	2,9 %	68,5 %	68,2 %	77,9 %
$n = 6$, $p = 3$, 600 obj.	75/25	aléatoire	1,7 %	71,4 %	71,5 %	76,3 %
		modèle unique	0,9 %	**90,2 %**	**92,2 %**	**81,1 %**
$n = 8$, $p = 4$, 600 obj.	50/50	aléatoire	4,7 %	**86,4 %**	**82,2 %**	**80,3 %**
		modèle unique	7,4 %	78,8 %	70,8 %	69,6 %

TABLE 2 – Validation sur données synthétiques sans bruit (moyenne de 3 essais par configuration, mêmes données pour les deux départs).

Le tableau 2 conduit à trois constats :

— **Bien expliquer les données ne suffit pas à retrouver les vrais modèles.** Les deux heuristiques expliquent presque parfaitement le learning set (1 à 7 % d'erreur), mais l'accord avec les vrais modèles n'est que de 68 à 92 %, et 69 à 90 % des objets discriminants sont remis dans leur vrai segment. Avec deux modèles, beaucoup de couples (partition, modèles) différents expliquent les mêmes données : c'est l'équivalent, pour deux segments, de la non-unicité des paramètres vue au jalon 1.

— **Le départ modèle unique est nettement meilleur sur les segments déséquilibrés** : en 75/25, il retrouve 90 % des objets discriminants (contre 71 %) et un modèle majoritaire en accord à 92 % avec le vrai (contre 72 %). Cela confirme l'intuition de la méthode : le modèle unique apprend d'abord le segment majoritaire.

— **En 50/50, aucune méthode ne domine** : le départ modèle unique l'emporte sur la configuration à 300 objets, le départ aléatoire sur les deux configurations à 600 objets. Le modèle unique est alors un compromis entre les deux comportements, et son point de départ est moins informatif. Avec seulement 3 essais par configuration, ces écarts de quelques points ne sont pas significatifs.

5.1 Interprétation : paires de modèles indistinguables

Notons M'_1 et M'_2 les modèles réels des deux segments, et M^*_1, M^*_2 les modèles appris. Deux modèles sont *équivalents* s'ils affectent chaque point de l'espace des critères $[0,1]^n$ à la même catégorie ; on mesure empiriquement leur proximité par la proportion de points, parmi 10 000 tirés au hasard, sur lesquels ils sont en désaccord. Au jalon 1, résoudre inv-MR-Sort permettait au mieux d'espérer un modèle équivalent au modèle réel (et non le modèle réel lui-même, ce qui est statistiquement improbable) ; en pratique on obtenait un modèle avec une petite erreur empirique.

Avec deux modèles, un second problème apparaît. Il peut exister une paire $(\tilde{M}_1, \tilde{M}_2)$ dont aucun modèle n'est équivalent à M'_1 ou à M'_2, mais qui *explique* les mêmes affectations : pour tout point x et toute catégorie k, si l'un des modèles réels affecte x à k, alors l'un des modèles $\tilde{M}_1, \tilde{M}_2$ affecte aussi x à k, et réciproquement, c'est-à-dire $\{\tilde{M}_1(x), \tilde{M}_2(x)\} = \{M'_1(x), M'_2(x)\}$. Cette condition tient compte du fait que les deux sources peuvent classer le même objet différemment : si les deux segments ont évalué le même produit, on observe ses deux catégories, et une paire qui explique les données doit les produire toutes les deux. Lorsque les sources ne sont pas indiquées dans les données, deux telles paires sont **indistinguables**, même si l'on connaissait le comportement des deux sources sur tout l'espace.

Ce cas existe pour des modèles MR-Sort. Sur $[0,1]^2$ avec deux catégories, prenons M'_1 : « accepté si $x_1 \geq 0{,}5$ » et M'_2 : « accepté si $x_2 \geq 0{,}5$ », puis $\tilde{M}_1$: « accepté si $x_1 \geq 0{,}5$ et $x_2 \geq 0{,}5$ » (poids $(\frac{1}{2}, \frac{1}{2})$, $\lambda = 1$) et $\tilde{M}_2$: « accepté si $x_1 \geq 0{,}5$ ou $x_2 \geq 0{,}5$ » (poids $(\frac{1}{2}, \frac{1}{2})$, $\lambda = \frac{1}{2}$). En tout point, $\{\tilde{M}_1(x), \tilde{M}_2(x)\} = \{M'_1(x), M'_2(x)\}$, alors que $\tilde{M}_1$ n'est équivalent ni à M'_1 ni à M'_2 (désaccord en $(1,0)$ et en $(0,1)$). Ce problème structurel est une source d'erreur sur laquelle nous n'avons aucune prise. Sur un dataset fini, il est d'autant plus probable : de nombreuses paires non équivalentes aux sources peuvent l'expliquer avec 0 % d'erreur. C'est ce qui explique l'écart entre la précision obtenue (93 à 99 %) et l'accord avec les vrais modèles (68 à 92 %).

Dans cet exemple, $\tilde{M}_1$ et $\tilde{M}_2$ sont le minimum et le maximum des deux sources : des modèles *hybrides*, l'un pessimiste, l'autre optimiste. Plus généralement, la paire $(\min(M'_1, M'_2), \max(M'_1, M'_2))$ explique toujours exactement les affectations des deux sources. Ces hybrides ne sont pas toujours des MR-Sort, mais il existe probablement une paire de MR-Sort proche d'eux, à la fois au sens de l'explication et au sens de l'équivalence. Nous faisons l'**hypothèse** (non vérifiée) que l'heuristique a un biais vers ce type de solution, et que ce biais explique les résultats du départ modèle unique :

— **en 50/50**, le modèle unique est proche d'un hybride des deux sources. Les objets qu'il classe bien et mal ne se séparent plus selon leur source, mais selon que leur catégorie est au-dessus ou en dessous de ce compromis. Toute la boucle d'apprentissage est alors biaisée vers une paire hybride, qui explique bien les données mais qui est l'un des pires cas au sens de l'équivalence deux à deux (proche de 50 % d'accord avec chaque source) ;

— **en 75/25**, l'hybride est déjà proche du modèle de la source majoritaire : ce biais ne gêne pas, et la partition de départ aide au contraire à séparer les deux sources.

6 Conclusion et limites

L'heuristique d'alternance partition / apprentissage, avec `lincs` pour apprendre chaque modèle, réduit l'erreur d'un modèle unique de 32 % à 7 % en 90 s, dont environ 5 points sont dus au bruit des données. Initialiser la partition à partir d'un modèle MR-Sort unique donne un bien meilleur point de départ, une convergence plus rapide et une erreur finale plus faible que le départ aléatoire, en particulier sur les datasets difficiles (type B, 1 200 objets) et déséquilibrés. La validation sur données synthétiques confirme cet avantage sur les segments déséquilibrés, où le départ modèle unique retrouve nettement mieux les vrais segments et les vrais modèles.

Il faut cependant garder en tête que nous n'avons **aucun moyen de savoir a priori** si la paire apprise s'approche d'une paire équivalente deux à deux à la paire source : la seule mesure dont nous disposons sur des données réelles est l'explicabilité des données, c'est-à-dire le taux d'erreur. Sans hypothèse supplémentaire, nous ne pouvons donc pas déterminer quelle heuristique est réellement la

meilleure. Avec des hypothèses sur les données, le choix devient possible : si l'on sait qu'une source prédomine nettement sur l'autre en nombre d'exemples, le départ modèle unique est à privilégier ; si l'on sait que les deux sources sont représentées à parts égales, nos résultats suggèrent que le départ aléatoire est préférable.

Trois limites sont à garder en tête :

— le taux d'erreur est mesuré sur les objets d'apprentissage : la validation synthétique montre que deux modèles peuvent expliquer presque parfaitement les données sans coïncider avec les vrais modèles (accord de 68 à 92 %). Les modèles appris sont des explications plausibles des données, pas nécessairement les comportements réels des deux segments ;

— la validation ne compte que 3 essais par configuration : elle suffit à montrer l'avantage du départ modèle unique en 75/25, mais pas à départager les deux méthodes en 50/50 ;

— le résultat dépend un peu de la charge de la machine, puisque chaque apprentissage `lincs` est limité en temps.