Projet SDP – Jalon 3

Attaquer l'apprentissage d'un modèle MR-Sort par injection de données

Mohamed Salh Mohamed Chebli Quentin Robidou

Novembre 2026

0 Cadrage du problème

0.1 Les acteurs

Un utilisateur A envoie à un utilisateur B un ensemble de données (x, k) classées par son modèle MR-Sort, afin que B apprenne ce modèle ou un modèle équivalent : c'est un problème inv-MR-Sort. Un attaquant C cherche à perturber cet apprentissage en ajoutant ses propres données, synthétiques, à celles de A. Nous nous plaçons du point de vue de C : il s'agit de concevoir la meilleure attaque possible.

0.2 Les hypothèses à faire varier

Le sujet nous laisse cadrer le problème. Dans tous les scénarios, B reçoit en une fois l'ensemble des données de A et de C, mélangées et sans date d'arrivée. Nous retenons trois hypothèses, qui définissent les scénarios :

1. **B se défend-il ?** Soit B apprend naïvement sur toutes les données reçues, soit il cherche à repérer et écarter les données de C.
2. **C a-t-il accès aux données envoyées par A ?** Uniquement aux données, jamais au modèle de A.
3. **Quelle part des données reçues par B provient de C ?** Au plus 50 %.

0.3 Ce que sait l'attaquant

C ne connaît que le contour du problème : le nombre de critères n, le nombre de catégories p, le fait que les évaluations sont dans $[0, 1]^n$ et que les critères sont à maximiser. Il ne connaît ni la façon dont le modèle de A a été choisi, ni la procédure d'apprentissage de B, ni la façon dont B se défend. Pour construire une attaque forte contre un MR-Sort quelconque, C a cependant besoin, dans certaines stratégies, de simuler un apprentissage : il simule alors une procédure inv-MR-Sort générique, offrant un minimum de robustesse, et nous prenons lincs (section 1). Ce n'est pas une hypothèse sur B, mais un manque d'alternative : C ne peut pas simuler la vraie stratégie de B, qu'il ne connaît pas, mais il peut simuler une procédure inv-MR-Sort générique.

0.4 Mesure de la qualité d'une attaque

Une attaque est d'autant meilleure que le modèle appris par B est éloigné de celui de A. Comme vu au jalon 1, deux modèles aux paramètres différents peuvent être équivalents : nous mesurons donc leur proximité de façon empirique, par la proportion de points sur lesquels ils prennent la même décision. Le score d'une stratégie s'obtient ainsi :

1. tirer un modèle MR-Sort A au hasard, et m_{train} objets uniformes dans $[0, 1]^n$ classés par A ;
2. C ajoute ses données ; si une part α des données reçues par B doit provenir de C, C ajoute $m_{\text{train}} \cdot \alpha/(1 - \alpha)$ objets (B s'entraîne donc sur plus de m_{train} objets) ;

3. B apprend un modèle sur l'ensemble, remélangé ;
4. sur m_{test} objets uniformes nouveaux, mesurer la proportion d'objets affectés à la même catégorie par A et par B (l'*accord*) ;
5. répéter sur plusieurs modèles A et faire la moyenne : le score de la stratégie est cet accord moyen, d'autant meilleur pour C qu'il est bas.

Chaque couple (stratégie, proportion) est évalué sur **ses propres modèles A**, tirés indépendamment (60 par couple, avec n entre 3 et 6 et p entre 2 et 4 tirés à chaque fois et communiqués à C, $m_{\text{train}} = 300$, $m_{\text{test}} = 10\,000$). Chaque score est ainsi une estimation indépendante de l'efficacité moyenne de la stratégie à cette proportion, que nous accompagnons de son intervalle de confiance à 95 %, et que nous comparons à une **référence sans attaque** ($\alpha = 0$), elle aussi estimée sur 60 modèles A.

0.5 Évaluer exactement le modèle appris

Le modèle appris par B doit être évalué tel que l'algorithme d'apprentissage le définit. lincs calcule en simple précision (nombres à virgule sur 32 bits, environ 7 chiffres significatifs) : il compare les évaluations aux profils et additionne les poids critère par critère dans ce format, et déclare une coalition suffisante si la somme atteint 1. Recalculer la concordance en double précision (64 bits) ne donne pas toujours le même modèle : trois poids de 0,33333299 font 0,99999997 < 1 en double précision, alors qu'en simple précision cette somme est arrondie à 1, le nombre représentable le plus proche. Sur certains modèles, la coalition change donc de statut, et le modèle évalué n'est plus celui que lincs a appris (dans un cas sans attaque, l'accord tombait ainsi à 62 % au lieu de 97 %). Nous reproduisons donc exactement le calcul de lincs ; sur 400 000 points de test, notre évaluation et celle de lincs ne divergent sur aucun.

1 Premier scénario : attaque à l'aveugle d'un apprentissage naïf

Ce premier scénario est le plus simple : C attaque **à l'aveugle** (sans accès aux données de A), et B **ne se défend pas**. Nous testons les parts de données de C suivantes : 10 %, 25 %, 1/3 et 50 %.

1.1 Choix de l'algorithme d'apprentissage de B

Il faut d'abord fixer ce que signifie « B ne se défend pas ». Nous nous plaçons du point de vue d'un B naïf, qui ne s'attend ni à être attaqué ni à recevoir des données bruitées. Deux algorithmes viennent naturellement de nos travaux précédents, et B pourrait préférer l'un ou l'autre pour des raisons sans rapport avec l'attaque :

— le **programme du jalon 1** (question vii), résolu avec Gurobi, qui maximise la marge α entre la concordance de chaque objet et le seuil λ (limité ici à 30 s) ;

— l'**heuristique de lincs** utilisée au jalon 2, qui cherche le modèle classant correctement le plus grand nombre d'objets (arrêt quand tout est bien classé, après 20 itérations sans progrès, ou après 30 s).

Il reste à choisir lequel rend l'expérience la plus intéressante. A priori, lincs semblait le moins intéressant : maximiser le nombre d'objets bien classés le rend plus robuste, ce qui risquait d'atténuer l'effet des attaques, et en particulier de désavantager injustement les attaques par données aléatoires, que lincs peut simplement sacrifier.

L'expérience a montré l'inverse. Le programme Gurobi est si peu robuste qu'il s'effondre à la moindre attaque. Dès que les données de A et de C sont incompatibles, aucune marge positive n'est possible, et la marge optimale vaut $\alpha^* = 0$: elle est atteinte par une solution triviale où toutes les concordances sont égales au seuil, ce qui place tous les objets dans la meilleure catégorie. Gurobi infère donc un modèle nul, quelle que soit l'attaque :

Part des données de C	0 %	10 %	25 %	1/3	50 %
lincs, données aléatoires	99,2 %	98,3 %	98,2 %	97,9 %	98,9 %
Gurobi, données aléatoires	99,3 %	8,2 %	8,2 %	8,2 %	8,2 %
Gurobi, autre modèle MR-Sort	99,1 %	8,2 %	8,2 %	8,2 %	8,2 %

TABLE 1 – Accord entre B et A pour un même modèle A ($n = 6$, $p = 3$). Avec Gurobi, toutes les attaques donnent exactement le même modèle dégénéré.

Avec Gurobi, toutes les stratégies produisent le même résultat, l'un des pires possibles : il devient impossible de déterminer quelle stratégie d'attaque est la meilleure. Imposer $\lambda \geq 0{,}5$, comme dans l'article de Leroy, Mousseau et Pirlot, ne suffit pas (accord moyen de 14 à 20 % sur 30 modèles), car d'autres solutions triviales de marge nulle existent. Nous retenons donc **lincs**, seul scénario à la fois crédible et intéressant.

1.2 Stratégies d'attaque

Sans connaître A, C peut seulement choisir où placer ses points et comment les étiqueter. Nous comparons six stratégies :

— **S1 – Bruit aléatoire** : points uniformes, catégories tirées au hasard.

— **S2 – Autre modèle MR-Sort** : points uniformes, classés par un MR-Sort que C tire au hasard.

— **S3 – Catégorie extrême** : points uniformes, tous dans la meilleure catégorie, ou tous dans la pire (choix tiré au hasard). Ces données sont représentables par un MR-Sort, mais contredisent A presque partout.

— **S4 – Dictature d'un critère** : points uniformes, classés par un MR-Sort où un seul critère, tiré au hasard, décide de tout. Elle vise les poids plutôt que les profils.

— **S5 – Anti-monotone** : points uniformes, classés à l'envers d'un MR-Sort aléatoire (catégorie $p - 1 - k$). Aucun MR-Sort ne peut expliquer ces données.

— **S6 – Catégorie extrême au centre** : comme S3, mais avec des points dans $[0{,}25\,;0{,}75]^n$. Près des coins de l'espace, la catégorie de n'importe quel MR-Sort est presque toujours la pire ou la meilleure : seuls les points intérieurs ont une catégorie incertaine, et peuvent déplacer les profils.

1.3 Résultats

Sans attaque, B obtient $97{,}5 \pm 1{,}0$ % d'accord en moyenne avec A (98,5 % en médiane ; lincs converge mal sur 2 modèles sur 60, à 76 %).

Stratégie	10 %	25 %	1/3	50 %
S1 – Bruit aléatoire	$98{,}1 \pm 0{,}4$	$96{,}6 \pm 0{,}8$	$95{,}5 \pm 1{,}0$	$94{,}5 \pm 1{,}3$
S2 – Autre modèle MR-Sort	$97{,}5 \pm 0{,}5$	$96{,}2 \pm 0{,}8$	$94{,}0 \pm 1{,}3$	$72{,}2 \pm 4{,}5$
S3 – Catégorie extrême	$97{,}3 \pm 0{,}7$	$95{,}3 \pm 1{,}0$	$92{,}3 \pm 1{,}7$	$\mathbf{65{,}4 \pm 6{,}0}$
S4 – Dictature d'un critère	$97{,}4 \pm 0{,}6$	$95{,}7 \pm 1{,}0$	$92{,}5 \pm 1{,}4$	$\mathbf{68{,}1 \pm 4{,}0}$
S5 – Anti-monotone	$97{,}7 \pm 0{,}5$	$96{,}4 \pm 0{,}8$	$94{,}5 \pm 1{,}2$	$85{,}9 \pm 3{,}8$
S6 – Extrême au centre	$97{,}3 \pm 0{,}7$	$\mathbf{88{,}3 \pm 3{,}0}$	$\mathbf{79{,}7 \pm 3{,}7}$	$70{,}6 \pm 4{,}2$

TABLE 2 – Accord moyen (%) entre B et A selon la part des données de C, avec l'intervalle de confiance à 95 % (60 modèles A tirés indépendamment pour chaque case ; sans attaque : 97,5±1,0 %).

Le tableau 2 conduit aux constats suivants :

— **À 10 %, aucune attaque n'est efficace** : tous les scores restent dans l'intervalle de confiance de la référence sans attaque.

— **À 25 % et** $1/3$**, S6 est la meilleure stratégie**, et c'est la seule dont l'intervalle de confiance se détache nettement des autres ($88{,}3 \pm 3{,}0$ puis $79{,}7 \pm 3{,}7$ %). En concentrant ses points au centre de l'espace, C devient majoritaire dans cette zone, alors qu'il reste minoritaire sur l'ensemble des données : lincs, qui maximise le nombre d'objets bien classés, préfère céder sur cette zone. C'est la **proportion locale** des données de C qui compte, plus que leur proportion globale.

— **À 50 %, S3 et S4 sont les meilleures stratégies** ($65{,}4 \pm 6{,}0$ et $68{,}1 \pm 4{,}0$ %), sans qu'on puisse les départager, ni les séparer nettement de S6 et S2 ($70{,}6 \pm 4{,}2$ et $72{,}2 \pm 4{,}5$ %) : les intervalles se recouvrent. À parts égales, C n'a plus besoin de se concentrer : des données cohérentes et très éloignées de A sur tout l'espace suffisent.

— **Une attaque efficace doit être représentable par un MR-Sort.** Le bruit (S1) n'a presque aucun effet, même à 50 % ($94{,}5 \pm 1{,}3$ %), et les données anti-monotones (S5) sont nettement moins efficaces qu'un MR-Sort aléatoire (S2) à 50 % : lincs écarte facilement des données qu'aucun MR-Sort ne peut expliquer. Les stratégies les plus efficaces (S3, S4, S6) envoient au contraire des données cohérentes mais très éloignées d'un modèle typique.

— **Les problèmes à deux catégories résistent mieux** : à 50 %, l'accord vaut 70 % pour $p = 2$ contre 61 à 65 % pour $p = 3$ ou 4 avec S3, et 80 % contre 56 à 65 % avec S4.

Deux réserves : les intervalles restent larges à 50 %, car l'effet de l'attaque varie beaucoup d'un modèle A à l'autre ; et S3 et S6 choisissent au hasard la meilleure ou la pire catégorie, sans que nous sachions encore si l'un des deux choix est plus efficace.

2 Deuxième scénario : l'attaquant a accès aux données de A

Le cadre reste le même (B naïf qui apprend avec lincs), mais C reçoit désormais toutes les données envoyées par A, sans connaître son modèle. Il peut en inférer un modèle $\hat{A}$: les données de A n'étant pas bruitées, $\hat{A}$ appris avec lincs est très proche de A (98,3 % d'accord en moyenne). C choisit aussi un sens de décalage des catégories ($+1$ ou -1), celui qui laisse le moins d'étiquettes de $\hat{A}$ bloquées à une extrémité.

Pour l'une des stratégies, C doit simuler un apprentissage. Il ne connaît pas la procédure de B : il simule une procédure inv-MR-Sort générique, offrant un minimum de robustesse, et nous prenons lincs. L'objectif reste de construire un ensemble de données trompeur pour toute procédure de type inv-MR-Sort. Dans ce scénario, B ne se défend pas, et apprend lui aussi avec une procédure inv-MR-Sort générique : lincs, retenu en partie 1 pour des raisons similaires. Ce choix commun n'est pas fait pour avantager C, il vient du manque d'alternative ; mais il faut garder à l'esprit qu'à l'évaluation, l'attaque en est avantagée, puisque C simule exactement la procédure de B. Ce n'est plus le cas dans la partie 4, où B se défend.

2.1 Stratégies d'attaque

— **S7 – Modèle** $\hat{A}$ **décalé** : points uniformes, étiquetés par $\hat{A}$ décalé d'une catégorie. Ce modèle décalé est encore un MR-Sort, donc représentable, et il contredit $\hat{A}$ sur tous les objets qui ne sont pas déjà à une extrémité.

— **S8 – Copie à étiquette décalée** : C reprend les points mêmes de A et décale leur étiquette d'une catégorie (dans l'autre sens si elle est déjà à une extrémité). Le conflit est maximal : ce sont les mêmes objets, avec deux étiquettes différentes.

— **S9 – Viser les frontières** : C tire ses points autour des profils de $\hat{A}$, là où la catégorie bascule, et les étiquette du côté opposé à celui que $\hat{A}$ leur attribue.

— **S10 – Optimisation du placement** : l'attaque idéale consisterait à optimiser directement chaque point de C, ses n coordonnées et son étiquette, pour minimiser l'accord entre A et le modèle appris par B. Avec $\gamma\, m_{\text{train}}(n{+}1)$ paramètres (jusqu'à 2 100) et un objectif dont chaque évaluation demande un apprentissage, ce problème est hors de portée. Nous le simplifions en optimisant la *distribution* des points : C les place uniformément dans une boîte $[c-r,\, c+r]$ et les étiquette par $\hat{A}$ décalé ; les paramètres sont le centre c, la demi-largeur r et le sens du décalage, soit $n+2$ paramètres. Un algorithme génétique (10 individus, 7 générations) les optimise ; chaque individu est évalué en simulant l'apprentissage avec lincs et en mesurant l'accord entre le modèle obtenu et $\hat{A}$, avec de nouveaux points, une nouvelle graine et un nouvel échantillon d'évaluation à chaque fois, pour ne pas sur-optimiser contre une exécution particulière. L'accord n'étant pas une fonction dérivable des paramètres (fonction en escalier, apprentissage en boîte noire), une descente de gradient n'est pas possible. Cette stratégie, plus coûteuse (environ 1 min 20 par modèle A en médiane), n'a été évaluée que sur 10 modèles A par proportion, au lieu de 60.

2.2 Résultats

Stratégie	10 %	25 %	1/3	50 %
S3 – Catégorie extrême (aveugle)	$97{,}3 \pm 0{,}7$	$95{,}3 \pm 1{,}0$	$92{,}3 \pm 1{,}7$	$65{,}4 \pm 6{,}0$
S6 – Extrême au centre (aveugle)	$97{,}3 \pm 0{,}7$	$88{,}3 \pm 3{,}0$	$79{,}7 \pm 3{,}7$	$70{,}6 \pm 4{,}2$
S7 – Modèle $\hat{A}$ décalé	$96{,}9 \pm 0{,}6$	$91{,}9 \pm 1{,}4$	$89{,}8 \pm 1{,}9$	$55{,}0 \pm 2{,}7$
S8 – Copie à étiquette décalée	$97{,}6 \pm 0{,}5$	$94{,}8 \pm 1{,}0$	$94{,}2 \pm 1{,}0$	$51{,}5 \pm 4{,}1$
S9 – Viser les frontières	$96{,}2 \pm 0{,}6$	$91{,}7 \pm 1{,}2$	$87{,}5 \pm 1{,}6$	$79{,}3 \pm 2{,}3$
S10 – Optimisation (10 modèles)	$\mathbf{88{,}5 \pm 3{,}1}$	$\mathbf{69{,}9 \pm 8{,}1}$	$\mathbf{62{,}1 \pm 9{,}1}$	$\mathbf{23{,}1 \pm 13{,}8}$

TABLE 3 – Accord moyen (%) entre B et A selon la part des données de C, avec l'intervalle de confiance à 95 % (60 modèles A tirés indépendamment par case, 10 pour S10 ; sans attaque : $97{,}5 \pm 1{,}0$ %). Les stratégies à l'aveugle S3 et S6 sont rappelées de la partie 1.

Le tableau 3 conduit aux constats suivants :

— **À 50 %, connaître les données de A donne un avantage net.** La copie à étiquette décalée et le modèle $\hat{A}$ décalé font tomber l'accord à $51{,}5 \pm 4{,}1$ et $55{,}0 \pm 2{,}7$ %, nettement en dessous de la meilleure stratégie à l'aveugle (catégorie extrême, $65{,}4 \pm 6{,}0$ %) : contredire exactement A sur tout l'espace est plus efficace que de contredire un modèle typique.

— **En dessous de 50 %, les stratégies simples ne suffisent pas.** À 25 % et 1/3, S7, S8 et S9 font moins bien que S6, qui n'utilise pas les données de A : C reste minoritaire partout, et les contradictions qu'il répartit sur tout l'espace sont écartées par lincs. Seule la concentration des points (S6) paie.

— **Ce qui paie le plus, c'est de pouvoir simuler l'apprentissage.** L'optimisation S10 est la meilleure stratégie à toutes les proportions, avec des intervalles séparés de ceux des autres stratégies, même sur 10 modèles. C'est la seule à agir dès 10 % ($88{,}5 \pm 3{,}1$ %, contre 96 à 98 % pour les autres), et à 50 % elle fait tomber l'accord à $23{,}1 \pm 13{,}8$ % : B apprend un modèle en désaccord avec A sur plus des trois quarts de l'espace en moyenne. Elle ne cherche pourtant qu'une dizaine de paramètres, avec 80 évaluations.

— **La proportion locale reste la clé.** S10 ne fait que choisir où concentrer les points de C et dans quel sens décaler les étiquettes : c'est la généralisation de l'idée de S6, placée là où elle fait le plus de dégâts pour le modèle A attaqué.

Les résultats de S10 ne portent que sur 10 modèles par proportion et un seul lancement de l'algorithme génétique par modèle : les intervalles de confiance sont larges. Sur un modèle par proportion, l'optimisation échoue presque complètement (accord de 98 % à 25 % et à 1/3, de 75 % à 50 %), ce qui élargit ces intervalles.

3 Troisième scénario : B se défend

B sait désormais qu'un attaquant peut injecter des données, sans savoir s'il y en a un, ni quelle stratégie il suit, ni dans quelle proportion. Nous nous plaçons dans le cadre de la partie 1 : C attaque à l'aveugle avec l'une des stratégies S1 à S6. Nous procédons en trois phases : des défenses spécialisées, chacune conçue contre une famille d'attaques (phase 1) ; une défense hybride, qui détecte l'attaque puis applique la défense adaptée (phase 2) ; enfin la meilleure réponse de C face à ces défenses (phase 3).

3.1 Défenses spécialisées

— **D0 – Aucune défense** (contre S1) : B apprend avec lincs, comme dans les parties 1 et 2. lincs maximise le nombre d'objets bien classés, ce qui suffit à écarter le bruit.

— **D1 – Plus grand segment** (contre S2) : si C envoie des données classées par un autre MR-Sort, le jeu reçu est un mélange de deux MR-Sort. B apprend deux modèles avec l'heuristique du jalon 2 (départ « modèle unique », 30 s par apprentissage) et garde celui qui explique le plus d'objets, en supposant que A est majoritaire.

— **D2 – Nettoyage de la monotonie** (contre S3, S5 et S6) : un objet qui en domine un autre sur tous les critères ne peut pas avoir une catégorie inférieure dans un MR-Sort. B retire, un par un, l'objet impliqué dans le plus de violations de cette règle, jusqu'à ce qu'il n'en reste plus, puis apprend avec lincs sur les objets restants.

— **D3 – Rejet du dictateur** (contre S4) : B apprend deux modèles comme pour D1 ; si un seul des deux est dictatorial (un critère suffit à lui seul à atteindre le seuil de majorité), il garde l'autre, sinon il garde celui du plus grand segment.

Les modèles appris par D1 et D3 sont évalués exactement comme ceux de lincs (section 0), y compris pendant l'heuristique à deux modèles, quand elle réaffecte les objets aux segments.

3.2 Phase 1 : chaque défense contre chaque attaque

Chaque défense est évaluée sans attaque, et contre chaque stratégie à 1/3 et 50 %, les deux proportions où les attaques de la partie 1 ont un effet. Faute de temps (l'heuristique à deux modèles prend environ 30 s par jeu), chaque case n'a que 20 modèles A, tirés indépendamment.

Le tableau 4 conduit aux constats suivants :

— **Le nettoyage de la monotonie (D2) est la meilleure défense isolée.** Il ne coûte rien sans attaque (98,6 %, comme D0), et c'est la défense dont le pire cas est le meilleur (65,1 %, contre S4 à 50 %). Son avance sur D3 (64,4 %) n'est toutefois pas significative.

— **Ne rien faire reste souvent le meilleur choix.** lincs seul est le meilleur, ou à égalité, dans 5 cas sur 12, en particulier à 1/3 : à cette proportion, seule S6 le fait descendre sous 90 %.

— **Les défenses à deux modèles coûtent cher sans attaque** : environ 15 points (81,4 et 83,5 %). Sur des données non attaquées, l'heuristique coupe en deux un jeu qu'un seul MR-Sort explique, et garde un modèle appris sur une partie seulement des données. Elles sont aussi très variables d'un modèle A à l'autre (intervalles de ±5 à ±16 points).

— **D1 ne protège pas contre S2**, l'attaque qu'elle visait : à 50 %, elle fait moins bien que lincs seul (62,6 contre 81,8 %). Quand les deux parts du jeu sont de même taille, garder le plus grand segment revient à choisir presque au hasard entre A et le modèle de C.

Attaque	C	D0 – aucune	D2 – monotonie	D1 – plus grand segment	D3 – rejet du dictateur
Sans attaque	0	**98,6 ± 0,3**	**98,6 ± 0,4**	81,4 ± 5,6	83,5 ± 8,0
S1 – Bruit	1/3	94,6 ± 1,8	**96,7 ± 1,1**	92,6 ± 4,7	86,1 ± 10,4
	50 %	**95,1 ± 2,5**	93,3 ± 2,0	91,5 ± 3,8	86,1 ± 8,0
S2 – Autre MR-Sort	1/3	**95,4 ± 2,2**	94,7 ± 1,6	86,0 ± 5,9	89,6 ± 8,1
	50 %	**81,8 ± 4,3**	74,0 ± 4,6	62,6 ± 9,3	70,4 ± 9,9
S3 – Extrême	1/3	**95,2 ± 2,8**	90,9 ± 3,3	74,3 ± 11,1	85,5 ± 8,1
	50 %	61,3 ± 11,5	**70,0 ± 7,8**	52,7 ± 16,2	66,9 ± 10,2
S4 – Dictature	1/3	**92,0 ± 2,7**	91,5 ± 3,1	85,7 ± 8,8	86,0 ± 7,0
	50 %	67,3 ± 7,7	65,1 ± 5,5	67,1 ± 10,6	**70,0 ± 6,5**
S5 – Anti-monotone	1/3	93,0 ± 2,5	**94,2 ± 2,2**	92,9 ± 4,8	91,2 ± 4,5
	50 %	82,8 ± 5,5	76,3 ± 8,2	83,7 ± 11,8	**87,8 ± 7,7**
S6 – Extrême centre	1/3	78,0 ± 4,9	72,4 ± 8,8	**83,1 ± 8,1**	81,6 ± 9,8
	50 %	70,5 ± 8,2	**77,0 ± 7,3**	51,6 ± 11,4	64,4 ± 11,9
Pire cas sous attaque		61,3	**65,1**	51,6	64,4

TABLE 4 – Accord moyen (%) entre B et A pour chaque défense, avec l'intervalle de confiance à 95 % (20 modèles A tirés indépendamment pour chaque case). En gras, la meilleure défense de chaque ligne.

— **Chaque défense spécialisée ne gagne que dans quelques cas**, et souvent sans écart significatif : D3 contre S4 et S5 à 50 %, D1 contre S6 à 1/3, D2 contre S3 et S6 à 50 %. Aucune défense ne domine les autres partout, d'où l'idée de la phase 2 : détecter l'attaque, puis choisir la défense.

Avec 20 modèles par case, les écarts de moins de 5 à 10 points sont rarement significatifs. La colonne D0 refait l'expérience de la partie 1 avec d'autres modèles A : elle la retrouve à 4 points près, sauf contre S2 à 50 % (81,8 contre 72,2 %), un écart qui rappelle que ces moyennes varient encore d'un tirage à l'autre.

3.3 Phase 2 : détecter l'attaque, puis choisir la défense

Le détecteur. B calcule sur le jeu reçu quelques indicateurs : n et p ; la part des objets impliqués dans une violation de monotonie, et la plus grande part des violations portée par un même objet ; la part de la catégorie la plus fréquente et celle de la catégorie extrême la plus fréquente ; la concentration des points au centre de l'espace (part des points dans $[0{,}25\,;0{,}75]^n$, rapportée à celle de points uniformes) ; la meilleure précision d'un classement sur un seul critère ; et l'ajustement d'un MR-Sort appris par lincs sur tout le jeu. Un arbre de décision (profondeur 5, au moins 5 jeux par feuille) prédit à partir de ces indicateurs l'une des 13 situations de la phase 1 : pas d'attaque, ou l'une des six stratégies à 1/3 ou à 50 %. L'arbre est appris **une seule fois**, sur des jeux que B simule lui-même en tirant des modèles A au hasard et en jouant chaque attaque (30 jeux par stratégie et par proportion, 60 sans attaque). Il prédit la bonne situation sur 53 % de ces jeux, et sur 42 % en validation croisée à 5 plis.

La redirection. B applique ensuite la défense qui avait le meilleur accord moyen dans la phase 1 pour la situation prédite (les cases en gras du tableau 4) ; s'il prédit qu'il n'y a pas d'attaque, il applique D2, à égalité avec D0 sur cette ligne. La défense hybride est évaluée sur 60 nouveaux modèles A par case, tirés indépendamment de ceux qui ont servi à apprendre l'arbre et à choisir la redirection.

Le tableau 5 conduit aux constats suivants :

— **lincs seul et D2 sont déjà de très bonnes défenses.** Sur la plupart des cases, ils font mieux que les défenses à deux modèles, et sur les autres ils en sont très proches (tableau 4) :

Attaque	C	Hybride (60)	lincs seul, partie 1 (60)	D2 (20)	Situation reconnue
Sans attaque	0	$98{,}2 \pm 0{,}3$	$97{,}5 \pm 1{,}0$	$98{,}6 \pm 0{,}4$	56/60
S1 – Bruit	1/3	$96{,}0 \pm 0{,}7$	$95{,}5 \pm 1{,}0$	$96{,}7 \pm 1{,}1$	31/60
	50 %	$91{,}7 \pm 2{,}2$	$94{,}5 \pm 1{,}3$	$93{,}3 \pm 2{,}0$	0/60
S2 – Autre MR-Sort	1/3	$94{,}0 \pm 0{,}9$	$94{,}0 \pm 1{,}3$	$94{,}7 \pm 1{,}6$	5/60
	50 %	$72{,}8 \pm 4{,}5$	$72{,}2 \pm 4{,}5$	$74{,}0 \pm 4{,}6$	17/60
S3 – Extrême	1/3	$90{,}8 \pm 1{,}8$	$92{,}3 \pm 1{,}7$	$90{,}9 \pm 3{,}3$	0/60
	50 %	$64{,}8 \pm 4{,}9$	$65{,}4 \pm 6{,}0$	$70{,}0 \pm 7{,}8$	29/60
S4 – Dictature	1/3	$92{,}3 \pm 1{,}4$	$92{,}5 \pm 1{,}4$	$91{,}5 \pm 3{,}1$	25/60
	50 %	$70{,}7 \pm 4{,}6$	$68{,}1 \pm 4{,}0$	$65{,}1 \pm 5{,}5$	0/60
S5 – Anti-monotone	1/3	$93{,}4 \pm 1{,}1$	$94{,}5 \pm 1{,}2$	$94{,}2 \pm 2{,}2$	33/60
	50 %	$83{,}9 \pm 4{,}1$	$85{,}9 \pm 3{,}8$	$76{,}3 \pm 8{,}2$	30/60
S6 – Extrême centre	1/3	$76{,}8 \pm 4{,}8$	$79{,}7 \pm 3{,}7$	$72{,}4 \pm 8{,}8$	45/60
	50 %	$69{,}0 \pm 4{,}2$	$70{,}6 \pm 4{,}2$	$77{,}0 \pm 7{,}3$	49/60
Pire cas sous attaque		64,8	65,4	65,1	

TABLE 5 – Accord moyen (%) entre B et A pour la défense hybride, comparée à lincs seul (partie 1) et au nettoyage de la monotonie (phase 1), avec l'intervalle de confiance à 95 % (entre parenthèses, le nombre de modèles A par case). Dernière colonne : nombre de jeux pour lesquels l'arbre a reconnu la bonne attaque et la bonne proportion.

il reste peu de marge à une défense plus élaborée.

— **La défense hybride est un bon compromis entre les deux.** Elle est aussi bonne que lincs seul et D2 sur la plupart des cases, parfois un peu meilleure (contre S4 à 50 % : 70,7 % contre 68,1 et 65,1 %), parfois un peu moins bonne (contre S1 à 50 % : 91,7 contre 94,5 %), sans écart significatif. Son pire cas (64,8 %, contre S3 à 50 %) est celui de lincs seul et de D2. Elle ne coûte presque rien sans attaque (98,2 %) et, surtout, n'a jamais l'effondrement des défenses à deux modèles appliquées à l'aveugle.

— **Le détecteur reconnaît bien les attaques qui laissent une trace.** L'absence d'attaque est reconnue dans 56 cas sur 60, et S6 dans tous les cas (la concentration au centre est visible), avec la bonne proportion dans 75 à 80 % des cas. Le premier critère de l'arbre est l'ajustement de lincs sur le jeu reçu : un jeu qu'un seul MR-Sort explique parfaitement est déclaré sain.

— **Les attaques mal reconnues sont surtout celles qui font peu de dégâts** : S3 à 1/3 (0 sur 60), S2 à 1/3 (5 sur 60) ou le bruit, que lincs écarte de toute façon. Une erreur de détection coûte alors peu, car la défense choisie à tort est le plus souvent D0 ou D2.

La limite de cette approche est celle de la phase 1 : la redirection ne peut pas faire mieux que la meilleure défense de chaque situation, et contre S3 et S6 à 50 % aucune défense ne remonte nettement l'accord. Ces deux attaques restent les points faibles de B, et c'est par là que C peut répondre.

3.4 Phase 3 : la réponse de C

C attaque toujours à l'aveugle (il ne connaît que n et p), mais sait que B peut se défendre. Il cherche une stratégie qui batte la défense hybride tout en restant efficace contre les autres défenses. Nous partons de S3, la meilleure attaque à 50 % : tous les points de C sont dans une catégorie extrême e, la pire ou la meilleure, tirée au hasard. Au lieu de les répartir uniformément, C les place là où cette étiquette contredit le plus A : si e est la pire catégorie, dans une boîte du haut de l'espace, là où tout MR-Sort classe haut ; si e est la meilleure, dans la boîte symétrique du bas. Nous comparons cinq placements, pour e la pire catégorie (le cas e meilleure est symétrique) : $[0\,;1]^n$ (S3), $[0{,}25\,;1]^n$ (décalée), $[0{,}5\,;1]^n$ (haute), $[0{,}4\,;0{,}9]^n$ (S6 décalée) et une moitié des points uniformes, l'autre au centre (mélange de S3 et S6).

Placement des points	C	lincs seul	D2	Hybride	Pire cas pour C
S3 : $[0\,;1]^n$	1/3	$91{,}1 \pm 3{,}0$	$88{,}9 \pm 3{,}2$	$91{,}7 \pm 3{,}2$	91,7
	50 %	$59{,}4 \pm 10{,}7$	$57{,}2 \pm 7{,}5$	$60{,}1 \pm 8{,}7$	60,1
Décalée : $[0{,}25\,;1]^n$	1/3	$90{,}5 \pm 5{,}0$	$83{,}4 \pm 6{,}8$	$80{,}9 \pm 6{,}8$	90,5
	50 %	$43{,}4 \pm 13{,}5$	$47{,}2 \pm 11{,}8$	$42{,}6 \pm 14{,}0$	47,2
Haute : $[0{,}5\,;1]^n$	1/3	$82{,}4 \pm 9{,}9$	$80{,}7 \pm 7{,}8$	$70{,}1 \pm 10{,}2$	**82,4**
	50 %	$30{,}8 \pm 13{,}5$	$47{,}0 \pm 15{,}2$	$17{,}6 \pm 10{,}3$	**47,0**
S6 décalée : $[0{,}4\,;0{,}9]^n$	1/3	$83{,}5 \pm 7{,}1$	$63{,}9 \pm 10{,}0$	$76{,}9 \pm 10{,}8$	83,5
	50 %	$52{,}4 \pm 10{,}4$	$58{,}0 \pm 11{,}2$	$42{,}9 \pm 9{,}5$	58,0
Mélange S3 et S6	1/3	$84{,}7 \pm 5{,}2$	$76{,}2 \pm 5{,}4$	$78{,}9 \pm 8{,}8$	84,7
	50 %	$62{,}6 \pm 7{,}6$	$69{,}2 \pm 9{,}4$	$59{,}1 \pm 7{,}8$	69,2

TABLE 6 – Accord moyen (%) entre B et A pour les variantes de S3, avec l'intervalle de confiance à 95 % (20 modèles A tirés indépendamment pour chaque case). Dernière colonne : l'accord contre la défense qui résiste le mieux.

La variante **haute** est la meilleure aux deux proportions (tableau 6) : elle fait mieux que S3 contre les trois défenses, et son pire cas passe de 91,7 à 82,4 % à 1/3, et de 60,1 à 47,0 % à 50 %. Elle exploite la monotonie de MR-Sort : un MR-Sort ne peut pas classer le haut de l'espace dans la pire catégorie sans y classer tout l'espace. Quand C est assez nombreux, lincs préfère donc tout mettre dans la pire catégorie, et le modèle appris s'effondre. Elle échappe aussi au détecteur : ses points ne sont pas concentrés au centre, et l'arbre, qui ne l'a jamais vue, la prend pour S3 et la renvoie vers D2 dans les 20 cas sur 20 à 50 %. L'écart entre l'hybride (17,6 %) et D2 (47,0 %) à 50 % vient donc du tirage des modèles A, et non de la défense : l'attaque est en tout ou rien, et selon le modèle A, lincs s'effondre complètement ou résiste.

Contre les défenses à deux modèles, la variante haute bat D1 ($80{,}6 \pm 6{,}8$ % à 1/3, $44{,}8 \pm 15{,}6$ % à 50 %) et D3 à 1/3 ($81{,}5 \pm 8{,}8$ %), mais **D3 lui résiste à 50 %** ($79{,}5 \pm 9{,}6$ %, contre 66,9 % face à S3). Les points de C étant tous dans la même catégorie, l'heuristique à deux modèles les isole dans un segment qu'elle explique par un modèle dégénéré, où un seul critère atteint le seuil de majorité : D3 le prend pour un dictateur et le rejette. C'est un effet de bord de la définition de D3, pas une détection de l'attaque. Nous avons essayé de rendre les données de C non dictatoriales (une partie des points dans le coin opposé, étiquetée à l'autre extrême), sans succès : l'heuristique apprend encore un modèle dictatorial pour C dans la moitié des cas.

Nous retenons la variante haute comme réponse de C. Il n'existe pas d'attaque meilleure que les autres contre toutes les défenses, ni de défense meilleure contre toutes les attaques : améliorer l'une contre un type de stratégie a tendance à la dégrader contre d'autres. Les variantes de S3 restent cependant globalement les meilleures attaques, car elles sont très difficiles à défendre ; leur seule parade, D3, coûte environ 15 points à B lorsqu'il n'y a pas d'attaque.

4 Quatrième scénario : l'attaquant a accès aux données de A, B se défend

Nous reprenons le cadre de la partie 2 (C reçoit les données de A et en infère $\hat{A}$) face à la défense hybride de la partie 3, en trois phases : les attaques informées de la partie 2 contre l'hybride ; une version informée de S3 ; enfin l'attaque la plus prometteuse contre toutes les défenses, qui constitue notre réponse finale.

4.1 Phase 1 : les attaques informées contre la défense hybride

La défense hybride ne protège pas mieux que lincs seul contre les attaques informées (tableau 7) : tous les écarts restent dans les intervalles de confiance, et la plupart sont même en faveur de C à 1/3. Le détecteur n'a jamais vu ces attaques ; il les prend le plus souvent pour S5 ou S3, et

Stratégie	C	Hybride	lincs seul (partie 2)
S7 – Modèle $\hat{A}$ décalé	1/3	$86{,}2 \pm 1{,}8$	$89{,}8 \pm 1{,}9$
	50 %	$56{,}1 \pm 4{,}3$	$55{,}0 \pm 2{,}7$
S8 – Copie à étiquette décalée	1/3	$91{,}7 \pm 2{,}9$	$94{,}2 \pm 1{,}0$
	50 %	$52{,}5 \pm 5{,}0$	$51{,}5 \pm 4{,}1$
S9 – Viser les frontières	1/3	$86{,}2 \pm 1{,}7$	$87{,}5 \pm 1{,}6$
	50 %	$77{,}5 \pm 3{,}3$	$79{,}3 \pm 2{,}3$
S10 – Optimisation (10 modèles)	1/3	$\mathbf{62{,}0 \pm 6{,}7}$	$62{,}1 \pm 9{,}1$
	50 %	$\mathbf{33{,}2 \pm 7{,}3}$	$23{,}1 \pm 13{,}8$

TABLE 7 – Accord moyen (%) entre B et A pour les attaques informées, contre la défense hybride et contre lincs seul, avec l'intervalle de confiance à 95 % (60 modèles A tirés indépendamment par case, 10 pour S10).

les renvoie vers D2, D3 ou D0, qui ne les contrent pas. S10, qui simule pourtant une procédure inv-MR-Sort générique et non la défense de B, reste la meilleure attaque informée. À 50 %, elle ne fait pas mieux que la variante haute, qui attaque à l'aveugle (17,6 %).

4.2 Phase 2 : S3 informée

C place ses points comme dans S3, tous dans une catégorie extrême, uniformément dans une boîte $[c - r,\, c + r]$, mais choisit la boîte et la catégorie grâce aux données de A. Un algorithme génétique, réglé comme pour S10 (10 individus, 7 générations), optimise le centre c, la demi-largeur r et la catégorie (pire ou meilleure) ; chaque individu est évalué en simulant une procédure inv-MR-Sort générique (lincs) et en mesurant l'accord entre le modèle obtenu et $\hat{A}$. C ne simule pas la défense hybride : dans la réalité, l'attaquant ne sait pas comment le défenseur se défend, et le supposer serait une hypothèse forte ; il peut en revanche toujours simuler une procédure inv-MR-Sort générique. La population de départ contient S3, S6 et la variante haute, chacune dans les deux sens. L'attaque est évaluée contre la défense hybride sur 10 modèles A par proportion.

Attaque contre l'hybride	1/3	50 %
S3 informée (10 modèles)	$69{,}7 \pm 14{,}6$	$\mathbf{19{,}5 \pm 8{,}9}$
S10 (10 modèles)	$\mathbf{62{,}0 \pm 6{,}7}$	$33{,}2 \pm 7{,}3$
Variante haute, à l'aveugle (20 modèles)	$70{,}1 \pm 10{,}2$	$17{,}6 \pm 10{,}3$

TABLE 8 – Accord moyen (%) entre B, protégé par la défense hybride, et A, pour les trois meilleures attaques.

Les trois attaques sont proches, et leurs écarts restent dans les intervalles de confiance (tableau 8). L'algorithme génétique **retrouve de lui-même l'idée de la variante haute** : dans 15 cas sur 20, il choisit une boîte dans le bas de l'espace (centre moyen entre 0,07 et 0,43), étiquetée dans la meilleure catégorie, et l'élargit à 50 % (demi-largeur jusqu'à 0,47). À 1/3, l'attaque réussit (accord de 38 à 67 %) quand l'hybride renvoie le jeu vers D2, et échoue (93 à 99 %) dans les 3 cas où il le renvoie vers D1 ou D3, d'où la largeur de l'intervalle.

4.3 Phase 3 : la réponse finale de C

Nous retenons la S3 informée, la meilleure attaque à 50 % contre l'hybride, qui généralise la variante haute en s'adaptant à chaque modèle A, et l'évaluons contre toutes les défenses (10 modèles A par case).

Défense de B	1/3	50 %
D0 – lincs seul	$54{,}9 \pm 11{,}0$	$\mathbf{6{,}1 \pm 3{,}8}$
D2 – Nettoyage de la monotonie	$\mathbf{53{,}3 \pm 6{,}4}$	$22{,}7 \pm 11{,}7$
D1 – Plus grand segment	$69{,}5 \pm 16{,}7$	$9{,}0 \pm 7{,}9$
Hybride (phase 2)	$69{,}7 \pm 14{,}6$	$19{,}5 \pm 8{,}9$
D3 – Rejet du dictateur	$75{,}3 \pm 15{,}5$	$89{,}4 \pm 16{,}0$

TABLE 9 – Accord moyen (%) entre B et A face à la S3 informée, pour chaque défense, avec l'intervalle de confiance à 95 % (10 modèles A tirés indépendamment par case).

Contre lincs seul, D2, D1 et l'hybride, la S3 informée est l'attaque la plus forte de ce travail (tableau 9) : à 50 %, l'accord tombe entre 6 et 23 %, et à 1/3 entre 53 et 70 %. Sa seule parade est D3, qui la neutralise presque à 50 % (plus de 93 % d'accord dans 9 cas sur 10), pour la même raison qu'avec la variante haute : à parts égales, l'heuristique à deux modèles sépare proprement les données de C, toutes dans la même catégorie, de celles de A, les explique par un modèle dégénéré que D3 rejette, et B garde le modèle appris sur les seules données de A. Mais cette parade est un mauvais choix pour B : D3 coûte environ 15 points lorsqu'il n'y a pas d'attaque (83,5 %), reste moins bonne que lincs seul contre la plupart des attaques à l'aveugle (tableau 4), et B ne peut pas savoir à l'avance qu'il fait face à cette attaque : le détecteur ne la lui a presque jamais désignée. **La S3 informée est notre réponse finale.**

Conclusion

Attaquer. Un attaquant minoritaire n'a presque aucun effet sur un apprentissage inv-MR-Sort, tant qu'il répartit ses données : lincs maximise le nombre d'objets bien classés et écarte des contradictions dispersées. Ce qui compte est la *proportion locale* : en concentrant ses points dans une zone bien choisie, C y devient majoritaire alors qu'il reste minoritaire globalement. La structure de MR-Sort fournit cette zone : sa monotonie empêche de classer le haut de l'espace dans la pire catégorie sans y classer tout l'espace, si bien que des points étiquetés à l'extrême opposé de ce que tout MR-Sort leur attribue forcent l'apprentissage à choisir entre A et C. Les attaques les plus efficaces envoient ainsi des données cohérentes, représentables par un MR-Sort, mais contraires au modèle de A. Connaître les données de A et pouvoir simuler une procédure inv-MR-Sort générique permet d'adapter ce placement à chaque modèle A : l'optimisation retrouve d'elle-même la variante haute, et fait tomber l'accord de B avec A à quelques pourcents lorsque C fournit la moitié des données.

Se défendre. lincs seul et le nettoyage de la monotonie sont déjà de très bonnes défenses contre les attaques simples : ils écartent le bruit et les données incohérentes sans rien coûter lorsqu'il n'y a pas d'attaque. Les défenses fondées sur deux modèles coûtent cher en l'absence d'attaque et sont très variables. La défense hybride, qui détecte l'attaque puis choisit la défense, est un bon compromis : aussi bonne que les meilleures défenses sur la plupart des situations, sans leur effondrement. Mais elle ne fait pas mieux que la meilleure défense de chaque situation, et ne reconnaît que les attaques qu'elle a vues pendant son apprentissage.

Un jeu de compromis. Aucune attaque n'est meilleure que les autres contre toutes les défenses, et aucune défense n'est meilleure contre toutes les attaques : améliorer l'une contre un type de stratégie la dégrade contre d'autres. La variante haute et la S3 informée battent toutes les défenses sauf D3, qui les contre par un effet de bord, mais que B a toutes les raisons de ne pas choisir. Les variantes de S3 sont globalement les meilleures attaques, car très difficiles à défendre : face à des données cohérentes mais contraires à A, un apprenant qui ne sait pas quelle part de ses données est fiable n'a pas de moyen sûr de les écarter.

Limites. Nos conclusions reposent sur 10 à 60 modèles A par situation ; avec 10 ou 20 modèles, les intervalles de confiance restent larges, et beaucoup d'écarts de moins de 10 points ne sont pas significatifs. Nous n'avons étudié que deux proportions pour les défenses (1/3 et 50 %), une seule procédure d'apprentissage (lincs) et des données de A non bruitées. Enfin, le tableau 1 de la partie 1 a été obtenu avant la correction de la section 0 et n'a pas été recalculé.